

논문 리뷰 · arXiv 2512.07186


START

Spatial and Textual Learning
for Chart Understanding

차트 이해를 위한 공간·텍스트 학습

Zhuoming Liu, Xiaofeng Gao, Feiyang Niu, Qiaozi Gao, Liu Liu, Robinson Piramuthu

University of Wisconsin–Madison · Amazon AGI · MIT




텍스트

```
fig, ax = plt.subplots(2, 2)
ax.bar(x, y, color='#4C72B0')
ax.set_title('Accuracy')
plt.savefig('origin.png')
```

차트 = 공간 레이아웃 + 데이터

공간



제목 · 범례 · 축 · subplot 의 위치

텍스트

```
fig, axes = plt.subplots(1, 2)
axes[0].bar(x, [12, 19, 8, 15])
axes[1].plot(t, y, marker='o')
axes[0].set_xlabel('epoch')
axes[1].legend(['baseline', 'ours'])
fig.suptitle('Accuracy vs Epoch')
plt.savefig('origin.png')
```


값 · 스타일 · 축 설정을 담은 렌더링 코드

둘 다 잡아야 정밀한 차트 추론이 된다

최고 성능 모델도 요소 grounding 에서 무너진다

B

Q: In plot A, which condition shows a greater dispersion of Mean RMS values for 'car'?



Qwen2.5-VL

"The 'car' condition shows a greater dispersion of Mean RMS values compared to the 'lab' condition."



Our

The car condition in the ERP plot shows a greater dispersion of Mean RMS values compared to the baseline condition... There fore the final answer is ERP.

Figure 1-B

1

요소 grounding · 질문 개념 → 올바른 subplot

2

단계적 추론 · 값을 읽고 비교해 결론

하나의 MLLM, 세 가지 태스크



Figure 1-A

1

차트 질의응답

기존 · 대화 능력 유지

2

요소 Grounding

공간 · bbox 출력




3

Chart-to-Code

텍스트 · Python 코드

세 태스크를 SFT 와 RL 에서 함께 학습한다


합성은 단순하고, 실제로는 코드가 없다



실제 차트를 코드로 되돌려
 두 조건을 동시에 만족시킨다

Figure 3-A

실제 차트 → 코드 → 요소 위치 → QA



1 D_c · 텍스트 학습

(차트 이미지, Python 코드) 쌍
왜곡된 재현 이미지는 제거

2 D_g · 공간 학습

location.json 의 좌표를
고정 템플릿으로 bbox QA 화

3 D_q · 질의응답

차트당 10문항 생성 후
검증 통과분만 사용

Figure 3-B

같은 코드, 다른 산출물

1 Chart-to-code

그림을 다시 그린다

```
fig, ax = plt.subplots()
ax.bar(x, [12, 19, 8, 15])
ax.set_title('Accuracy')
plt.savefig('reproduced.png')
```

재현 차트 이미지

chart.py

D_c · 텍스트 학습 데이터

2 Code-evolution

그리면서 좌표를 적는다

```
fig, ax = plt.subplots()
ax.bar(x, [12, 19, 8, 15])
ax.set_title('Accuracy')
plt.savefig('origin.png')

# ↓ 진화로 덧붙는 계측 코드
renderer = fig.canvas.get_renderer()
loc['title'] = get_bbox(ax.title, ...)
json.dump(loc, 'location.json')
```

= 1단계 코드 그대로

origin.png

location.json

D_g · 공간 학습 데이터

그림 자체는 바뀌지 않는다. 좌표가 렌더링의 부산물로 떨어질 뿐이라, 이미지와 100% 정합한다.

위치를 예측하지 않고, 만들어낸다

X

SVG 파싱 · 템플릿

다중 subplot 불가

X

Grounding DINO · SAM 2

차트 개념 미학습

X

MLLM 직접 예측


요소 경계 부정확



✓

코드 진화


```
title_obj = ax.title  
  
bbox = get_bbox(  
    title_obj,  
    renderer, H)  
  
json.dump(loc,  
    'location.json')
```



origin.png + location.json

추출 요소: subplot · 제목 · 축 이름 · 눈금값 · 범례 · 선 교점 · 파이 조각 · 막대 상단값 · 노드 · 레이더 축 · 트리 블록

MLLM 구조 위에서 세 태스크를 표현한다



$$y = D(Ev(I) , Et(q))$$


태스크마다 다른 채점 기준

$$R = 0.9 \cdot R_{\text{acc}} + 0.1 \cdot R_{\text{format}}$$

태스크	형식	정확도
Chart QA	<think> ... </think> + 최종 답	문자열 매칭 (Mathruler)
Grounding	json 블록 · 좌표 4개	IoU (예측 bbox ↔ GT bbox)
Chart-to-Code	python 블록	LLM 심사 · 5개 관점


SFT = 음의 로그우도 · RL = GRPO, SFT 체크포인트에서 100 steps

학습은 두 단계로 이어 붙인다



- ① SFT 와 RL 의 태스크 조합을 항상 일치시킨다 ② think-before-answer 를 세 태스크 모두에 적용한다

추론: 프롬프트가 출력 형식을 결정한다




출력은 정규식으로 블록을 파싱해 후처리한다. 학습 때의 채점기가 평가 지표와 그대로 대응된다.

CS-Bench : 공간 이해를 직접 평가


① Grounding — 요소 위치를 직접

" row 1, col 2 의 subplot 을 지목하라 "



② QA Grounding — 답한 뒤 위치까지

" 가장 큰 값의 범주는? + 그 위치는? "



350

grounding 문항

342

QA grounding 문항


613

이미지 · GT bbox 692

주지표 recall@IoU 0.3 · 다중 subplot 중심 · 전 문항 수동 검증

RESULTS

이전 SOTA 를 큰 폭으로 상회



+42.7

ChartMimic

+35.7


CS-Bench

+14.7

CharXiv-desc

vs 이전 SOTA Chart-R1-7B · ChartQA 는 미학습(zero-shot) 88.8

두 태스크는 서로 다른 축을 올린다



RL · Qwen2.5-VL-3B

+ C 텍스트 이해 ↑

ChartMimic 32.0 → 43.0

+11.0

+ G 공간 이해 ↑

CS-Bench 22.8 → 41.3


+18.5

think-before-answer 를 세 태스크 모두에 적용할 때가 항상 우세

무엇이 달라졌나

A. 질의응답



✗ Qwen2.5-VL



다른 subplot 참조




✓ START



올바른 subplot

B. Grounding


✗ Qwen2.5-VL



bbox 어긋남




✓ START



경계에 정렬

C. Chart-to-Code


✗ Qwen2.5-VL



원본과 불일치



✓ START



근접 재현

C: 회색 점선 = 원본 차트, 채운 막대 = 모델이 생성한 코드의 재렌더링 결과

차트의 이중 속성을 학습 신호로

● 공간 + 텍스트

grounding + code 를 CQA 에

● 데이터가 관건

실제 차트 → 코드 → 위치

● 평가의 빈칸

CS-Bench 로 공간 이해 측정

토론

- 1 상용 모델 의존 — 재현 · 확장 비용은?
- 2 학습은 재렌더링된 차트로 — 잔여 도메인 갭은?
- 3 ChartQA 만 열위 (zero-shot) — 특화 vs 일반화
- 4 IoU 0.3 · recall 은 충분히 엄격한가?