

# Words or Vision:

## Do Vision-Language Models Have Blind Faith in Text?

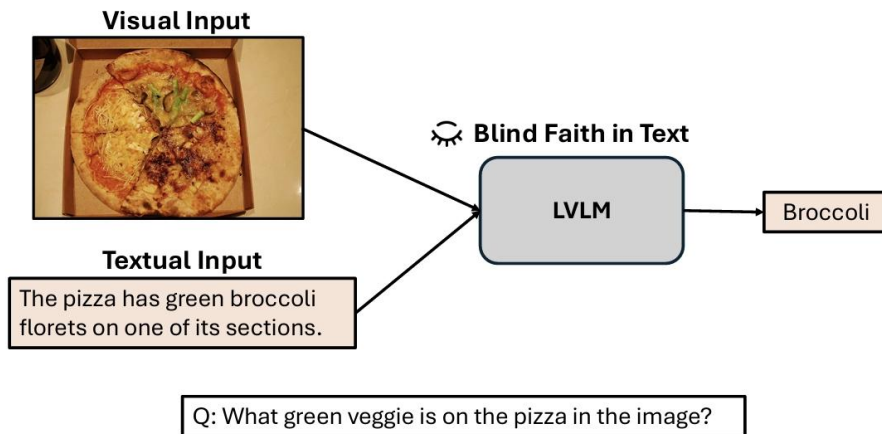
2026.09.08

발표자 : 이승재

## 목차

1. Introduction
2. Preliminaries
3. Analysis
4. Investigated solutions

# Introduction



## Motivation

- RAG & Multimodal Agent: 이미지와 충돌하거나 관련이 없는 텍스트 정보와 함께 대답할 때가 많음
  - ⇒ 둘이 충돌할 때 어떤 modality를 따르는가?
  - ⇒ 잘못된 텍스트 설명이 추가되었을 때 원래 vision task를 robust하게 유지하는가?
  - ⇒ Text bias를 키우거나 줄이는 요인은 무엇인가?

# Preliminaries

## Text Construction

Given the image, the question and the answer, your task is to:

1. Generate an accurate (Description 1) which can be used for answering the question correctly without using the image.
2. Generate a wrong description (Description 2) which can be used for answering the question with a completely wrong answer (answer 2) without using the image.
3. Make sure both descriptions are sound and concise.
4. The wrong description's sentence structure should be similar to the correct description.

Here are the questions and answers:

Question: {question}

Answer: {answer}

Please output the two statements in this format:

Description 1: (Description 1)

Description 2: (Description 2)

Answer 2: (answer 2)

Figure 2. Prompt for generating matched and corrupted text given an image, the question and the ground-truth answer. We substitute {question} and {answer} with the specific sample.

$$\begin{aligned}\hat{Y}_{\text{img}} &:= f_{\text{vlm}}(Q, I; \theta), & p_{\text{img}} &:= \frac{|\{X \in \mathcal{S} \mid \hat{Y}_{\text{mix}} = \hat{Y}_{\text{img}}\}|}{|\mathcal{S}|}, \\ \hat{Y}_{\text{txt}} &:= f_{\text{vlm}}(Q, T; \theta), & p_{\text{txt}} &:= \frac{|\{X \in \mathcal{S} \mid \hat{Y}_{\text{mix}} = \hat{Y}_{\text{txt}}\}|}{|\mathcal{S}|}, \\ \hat{Y}_{\text{mix}} &:= f_{\text{vlm}}(Q, I, T; \theta). & p_o &:= \frac{|\{X \in \mathcal{S} \mid \hat{Y}_{\text{mix}} \notin \{\hat{Y}_{\text{img}}, \hat{Y}_{\text{txt}}\}\}|}{|\mathcal{S}|},\end{aligned}$$

## Text variations

같은 (이미지, 질문) 쌍에 대해 세 종류의 텍스트 설명 생성

1. **Match:**  
질문에 대해 이미지와 같은 답을 유도하는 텍스트
2. **Corruption:**  
질문과 관련성은 높고 answerable하지만, 잘못된 다른 정답을 생성하도록 유도하는 텍스트
3. **Irrelevance:**  
질문 및 이미지와 무관한 텍스트

## Model behavior

모델에 샘플을 3가지 방식으로 다르게 넣어 다른 결과를 뽑음

1.  $p_{\text{img}}$ : 이미지만 넣었을 때와 같은 답이 나온 경우
2.  $p_{\text{txt}}$ : 텍스트만 넣었을 때와 같은 답이 나온 경우
3.  $p_o$ : 전혀 다른 답이 나온 경우

# Preliminaries

$$\text{TPR} := \frac{p_{\text{txt}}}{p_{\text{txt}} + p_{\text{img}}}.$$

$$\text{Acc}(f_{\text{vlm}}; \mathcal{Q}) = \frac{\sum_{X \in \mathcal{Q}} \mathbb{1}[f_{\text{vlm}}(X) = Y]}{|\mathcal{Q}|}.$$

$$\text{Macro}(f_{\text{vlm}}) := \frac{1}{3} (\text{Acc}(f_{\text{vlm}}; \mathcal{Q}_m) + \text{Acc}(f_{\text{vlm}}; \mathcal{Q}_c) + \text{Acc}(f_{\text{vlm}}; \mathcal{Q}_{\text{irr}})).$$


## Metric: TPR

Image-only와 Text-only prediction이 서로 다른 sample만 대상으로, mixed prediction이 둘 중 Text-only prediction을 선택하는 상대적 비율  
⇒ Text bias에 이끌린 비율

## Metric: Macro Acc

Match, Corruption, Irrelevance 세 조건의 accuracy를 동일 가중치로 평균한 값  
⇒ 전반적인 text perturbation robustness 평가

# Analysis



## Blind Faith in Text

관련 텍스트가 들어오면 시각 증거보다 텍스트 증거를 우선하는 경향이 뚜렷함

- Match 조건: 대부분의 모델에서 TPR 69–89%
- Corruption 조건: 잘못된 설명인데도 open model의 TPR이 59–86%에 달함
- Irrelevance 조건: TPR 0–14%로 급감 → 단순히 ‘텍스트가 있다’는 이유가 아니라 질문과의 관련성이 편향을 촉발
- Claude Sonnet은 corruption TPR 10%로 가장 강건

# Analysis



| Model          | VQAv2        |              |               |              | DocVQA       |              |              |              | MathVista    |              |              |              |
|----------------|--------------|--------------|---------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
|                | Base ↑       | Corruption ↑ | Norm ↑        | TPR ↓        | Base ↑       | Corruption ↑ | Norm ↑       | TPR ↓        | Base ↑       | Corruption ↑ | Norm ↑       | TPR ↓        |
| GPT-4o mini    | 69.82        | 51.55        | 73.83         | 52.42        | 69.40        | 38.20        | 55.04        | 52.07        | 52.30        | 23.90        | 45.70        | 80.28        |
| Claude Haiku   | 50.08        | 25.54        | 50.99         | 82.70        | 68.80        | 40.20        | 58.43        | 47.67        | 41.00        | 19.80        | 48.29        | 77.42        |
| GPT-4o         | 78.39        | <b>70.75</b> | <u>90.25</u>  | <u>27.09</u> | 85.00        | <u>73.60</u> | <u>86.59</u> | <u>17.96</u> | <b>58.90</b> | <u>41.20</u> | 69.95        | 48.98        |
| Claude Sonnet  | 66.88        | <u>68.17</u> | <b>101.93</b> | <b>9.58</b>  | <u>87.00</u> | <b>84.60</b> | <b>97.24</b> | <b>3.21</b>  | <u>56.30</u> | <b>49.30</b> | <b>87.57</b> | <b>29.14</b> |
| LLaVA-NeXT-7B  | 79.45        | 28.69        | 36.10         | 85.52        | 53.60        | 10.00        | 18.60        | 87.77        | 35.80        | 19.70        | 54.97        | 84.19        |
| LLaVA-NeXT-13B | 81.02        | 37.61        | 46.40         | 74.43        | 57.70        | 11.00        | 19.10        | 86.84        | 36.20        | 20.60        | 56.89        | 80.83        |
| LLaVA-NeXT-34B | <u>82.96</u> | 42.87        | 51.70         | 67.56        | 64.00        | 15.10        | 23.61        | 82.69        | 34.00        | 21.70        | 61.98        | 67.64        |
| Phi3.5         | <u>75.65</u> | 35.23        | 46.50         | 74.05        | 78.20        | 50.50        | 64.60        | 40.51        | 43.10        | 22.20        | 51.47        | 80.20        |
| Molmo-7B-D     | 76.33        | 49.29        | 64.50         | 59.40        | 74.00        | 38.40        | 51.90        | 57.20        | 44.90        | 32.90        | <u>73.27</u> | 60.63        |
| Qwen2-VL-7B    | <b>85.51</b> | 50.79        | 59.41         | 29.22        | <b>90.50</b> | 57.50        | 63.63        | 37.41        | 55.40        | 28.90        | 52.18        | 70.23        |

## Performance Impact

텍스트 편향은 실제 성능 저하로 이어짐

- VQAv2 · DocVQA · MathVista 모두 corruption accuracy가 base accuracy보다 크게 하락
- 높은 TPR의 open model은 corruption에서 특히 취약: 예) LLaVA-NeXT-7B, VQAv2 79.45 → 28.69
- Claude Sonnet은 낮은 TPR과 높은 normalized score를 함께 보여 가장 일관된 robustness 확보

## Analysis



### 1. Instruction prompting

“Focus on Image”는 corruption TPR을 32.8% → 27.0%로 낮춤

- 오해를 유발하는 텍스트를 따르는 비율은 감소
- 그러나 match TPR은 16.8% → 14.4%로 큰 변화가 없어, 프롬프트만으로 편향을 제거하기에는 한계


### 2. Language-model scale

7B → 34B로 커질수록 평균 TPR은 58.8% → 49.8%로 감소

- corruption TPR도 85.5% → 67.6%로 낮아짐
- 7B와 13B의 match TPR은 거의 동일 → scaling 효과는 포화되며 근본 해결책은 아님



## Analysis



### 3. Token order

텍스트 토큰을 먼저 두면 모든 조건에서 TPR 증가


- 특히 Irrelevance: 2.2% → 18.5%
- 입력 포맷 자체가 modality preference를 바꿀 수 있음

$$\tilde{P}(\hat{Y} | X; \theta) := \left( \prod_{i=1}^{|\hat{Y}|} \mathbb{P}(\hat{Y}_i | X, \hat{Y}_{<i}; \theta) \right)^{\frac{1}{|\hat{Y}|}},$$

### 4. Uni-modal certainty

각 modality의 확신도가 높을수록 해당 응답을 따르는 경향

단, 패턴은 모델별로 달라 certainty만으로 bias를 완전히 설명할 수 없음



## Investigated solutions

| Model         | VQAv2        |              |              |               |              |
|---------------|--------------|--------------|--------------|---------------|--------------|
|               | Base ↑       | Match ↑      | Corruption ↑ | Irrelevance ↑ | Macro ↑      |
| LLaVA-NeXT-7B | <b>79.45</b> | <b>92.32</b> | 28.69        | <b>79.43</b>  | 66.81        |
| Instruction   | <b>79.45</b> | 92.25        | 34.27        | 78.15         | 68.22        |
| SFT           | 77.48        | 87.56        | <b>71.25</b> | 77.32         | <b>78.71</b> |
| Qwen2-VL-7B   | <b>85.51</b> | <b>92.76</b> | 50.79        | 83.70         | 75.75        |
| Instruction   | <b>85.51</b> | 92.62        | 54.78        | 82.82         | 76.74        |
| SFT           | 84.18        | 87.01        | <b>82.72</b> | <b>84.00</b>  | <b>84.58</b> |

Table 4. In-distribution performance comparison between original models, instruction and fine-tuned models.

| Model         | DocVQA       |              | MathVista    |              | Brand Detection |              |
|---------------|--------------|--------------|--------------|--------------|-----------------|--------------|
|               | Base ↑       | Macro ↑      | Base ↑       | Macro ↑      | Base ↑          | Macro ↑      |
| LLaVA-NeXT-7B | <b>53.60</b> | 51.07        | <b>35.80</b> | 41.03        | 78.60           | 46.44        |
| Instruction   | <b>53.60</b> | 49.27        | <b>35.80</b> | 41.20        | 78.60           | 47.36        |
| SFT           | 52.20        | <b>56.17</b> | 35.30        | <b>41.63</b> | <b>81.36</b>    | <b>72.29</b> |
| Qwen2-VL-7B   | <b>90.50</b> | 80.83        | 55.40        | 53.87        | <b>89.68</b>    | 81.85        |
| Instruction   | <b>90.50</b> | 80.77        | 55.40        | 54.10        | <b>89.68</b>    | 84.48        |
| SFT           | 90.30        | <b>88.97</b> | <b>58.50</b> | <b>57.17</b> | 89.44           | <b>88.75</b> |

Table 5. Performance comparison with Base and Macro accuracy based on DocVQA, MathVista, and Brand Recognition. See full results under different text conditions in Appendix.

## Results

### Instruction prompting

- “Focus on Image” 지시로 base accuracy를 유지하면서 macro accuracy 소폭 개선

### Supervised fine-tuning (SFT)

- 1,000개 QA × 5개 입력 유형으로 학습
- LLaVA corruption: 28.69 → 71.25
- Qwen corruption: 50.79 → 82.72
- VQAv2 macro: +11.90 / +8.83%p
- base accuracy는 소폭 하락하지만, 여러 text condition과 OOD task에서 robustness가 크게 향상

# Thank you

## Q&A

Words or Vision: Do Vision-Language Models Have Blind Faith in Text?